INFO-H-303 Bases de données
Séance d'exercices 11
Normalisation

F. Servais et B. Verhaegen

4 décembre 2009

But de la normalisation

EmpDept

EName	SSN	BDate	Address	D#	DName	DMgrSSN
Smith	1234	21/07/39	...	1	Research	1234
Narayan	6668	18/01/43	...	1	Research	1234
English	4534	8/05/53	...	2	Account	4534
Wong	9788	30/11/49	...	3	Admin	9788
Zelaya	6677	23/08/60	...	3	Admin	9788

- Objectif : construire un schéma relationnel évitant la redondance
- La redondance implique des anomalies lors de
  - l'insertion (nouvel employé, nouveau département)
  - la suppression (du dernier employé d'un département)
  - la modification (changement de manager)

Dépendances fonctionnelles (DF)

EmpDept

EName	SSN	BDate	Address	D#	DName	DMgrSSN

$$\text{DF1 : } SSN \rightarrow \{EName, BDate, Address, D\#\}$$
$$\text{DF2 : } D\# \rightarrow \{DName, DMgrSSN\}$$

Soit $R(A_1, ..., A_n)$ avec $X, Y \subseteq \{A_1, ..., A_n\}$

Il y a une dépendance fonctionnelle $X \rightarrow Y$ (X détermine Y)
si pour chaque paire de tuple t_1, t_2 de R,
si $t_1[X] = t_2[X]$ alors $t_1[Y] = t_2[Y]$.

Règles d'inférences des DF

Axiomes d'Armstrong

- (Réflexivité) Si $Y \subseteq X$, alors $X \rightarrow Y$
- (Augmentation) Si $X \rightarrow Y$, alors $XZ \rightarrow YZ$ (et $XZ \rightarrow Y$)
- (Transitivité) Si $X \rightarrow Y$ et $Y \rightarrow Z$, alors $X \rightarrow Z$

Règles supplémentaires

- (Décomposition) Si $X \rightarrow YZ$, alors $X \rightarrow Y$ et $X \rightarrow Z$
- (Union) Si $X \rightarrow Y$ et $X \rightarrow Z$, alors $X \rightarrow YZ$
- (Pseudotransitivité) Si $X \rightarrow Y$ et $WY \rightarrow Z$, alors $WX \rightarrow Z$

Les 3 dernières règles sont des conséquences des 3 premières.

Couverture minimale d'un ensemble F de DF

Un ensemble F de DF couvre un ensemble G de DF si on peut inférer chaque DF de G avec les DF de F.

Deux ensembles de DF F et G sont équivalents si F couvre G et G couvre F.

Une couverture minimale d'un ensemble F de DF est un ensemble minimal de DF qui est équivalent à F. On parle aussi de graphe minimum des dépendances.

Couverture minimale : algorithme

Trouver une couverture minimale G de F

(1) $G \leftarrow F$

(2) Remplacer chaque DF $X \rightarrow \{A_1, \ldots, A_n\}$ dans G par n DF $X \rightarrow A_i$

(3) Pour chaque DF $X \rightarrow A$ dans G,
    pour chaque attribut B de X
        si $(G - \{X \rightarrow A\}) \cup \{(X - \{B\}) \rightarrow A\}$ est équivalent à G
        alors remplacer $X \rightarrow A$ par $(X - \{B\}) \rightarrow A$ dans G

(4) Pour chaque DF $X \rightarrow A$ restante dans G
    si $(G - \{X \rightarrow A\})$ est équivalent à G
        alors enlever $X \rightarrow A$ de G

Fermeture d'un ensemble d'attribut X

La fermeture d'un ensemble d'attributs X, $(X)^+$ représente l'ensemble des attributs de R qui peuvent être déduits de X a partir d'un ensemble F de DF et des règles d'inférences. La fermeture d'une clé est l'ensemble de tous les attributs de la relation.

Y est inclus dans $(X)^+$ si et seulement si $X \rightarrow Y$

Algorithme :

1. $(X)^+ \leftarrow X$
2. trouver une DF dans F dont la partie gauche est incluse dans $(X)^+$
3. ajouter dans $(X)^+$ la partie droite de cette DF
4. répéter les opérations 2 et 3 jusqu'à ce que $(X)^+$ n'évolue plus

Première forme normale

Une relation R est en première forme normale si :

- R respecte la définition du modèle relationnel
- R ne possède pas d'attribut composés ou multivalués

Toutes les relations que l'on a vu jusqu'à présent respectent la première forme normale.

Première forme normale : exemple

Department

DName	DNumber	DMgr	{DLocations}

Department

DName	DNumber	DMgr	{DLocations}
Research	5	333445555	{Bellaire,Sugarland,Houston}
Administration	4	987654321	{Stafford}
Headquarters	1	888665555	{Houston}

$\Downarrow$ 1NF Normalization

Department

DName	DNumber	DLocations	DMgr
Research	5	Bellaire	333445555
Research	5	Sugarland	333445555
Research	5	Houston	333445555
Administration	4	Stafford	987654321
Headquarters	1	Houston	888665555

Deuxième forme normale

Une relation R est en deuxième forme normale si :

- R est en première forme normale
- il n'y a pas d'attribut ne faisant pas partie d'une clé qui dépend d'une partie de cette clé

Deuxième forme normale : exemple

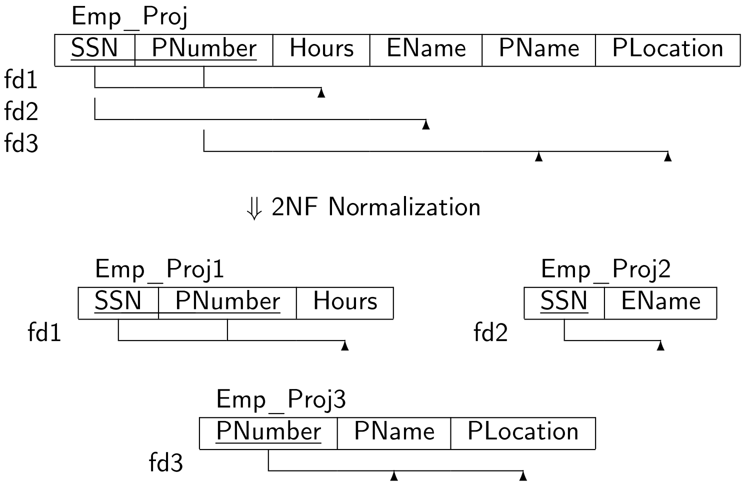

Troisième forme normale

Une relation R est en troisième forme normale si :

- R est en deuxième forme normale
- il n'y a pas d'attribut ne faisant pas partie d'une clé qui dépend transitivement de cette clé

Troisième forme normale : exemple

Emp_Dept

EName	SSN	BDate	Address	DNumber	DName	DMgr

$\Downarrow$ 3NF Normalization

Emp_Dept1

EName	SSN	BDate	Address	DNumber

Emp_Dept2

DNumber	DName	DMgr

Forme normale de Boyce-Codd (BCNF)

Une relation R est en BCNF si :

- R est en troisième forme normale
- la partie gauche de chaque DF est une clé candidate entière

La plupart des relations en troisième forme normale sont en BCNF.

Décomposition

Professeur	**Département**	**Faculté**
Esteban	CoDE	Polytech
Jean	DI	Sciences
Hugues	CoDE	Polytech
Olivier	LISA	Polytech

Professeur	**Faculté**
Esteban	Polytech
Jean	Sciences
Hugues	Polytech
Olivier	Polytech

Département	**Faculté**
CoDE	Polytech
DI	Sciences
LISA	Polytech

Perte d'information

Professeur	**Département**
Esteban	CoDE
Jean	DI
Hugues	CoDE
Olivier	LISA

Professeur	**Faculté**
Esteban	Polytech
Jean	Sciences
Hugues	Polytech
Olivier	Polytech

Perte de DF

Professeur	**Département**
Esteban	CoDE
Jean	DI
Hugues	CoDE
Olivier	LISA

Département	**Faculté**
CoDE	Polytech
DI	Sciences
CoDE	Polytech
LISA	Polytech

Bonne décomposition

Décomposition sans perte

Lors de la décomposition, il faut veiller à ne perdre ni information ni dépendance fonctionnelle.

Soit une relation R décomposée en deux relations $R1$ et $R2$. Si l'ensemble des attributs communs de $R1$ et $R2$ est une clé d'une des deux relations, alors la décomposition est sans perte d'information.

Si dans une relation R on peut trouver trois ensembles d'attributs A,B et C tel qu'il existe une dépendance fonctionnelle $A \to B$, alors R peut être décomposée en deux relations $R1(A, B)$ et $R2(A, C)$ sans perte d'information.

Algorithme de décomposition combinée

Décomposition sans perte d'information et sans perte de dépendance fonctionnelle

1. trouver un ensemble minimum G de F
2. pour chaque X d'une DF $X \rightarrow A$ de G

    créer une relation dans D avec les attributs $\{X \cup A_1 \cup \ldots \cup A_k\}$
    où $X \rightarrow A_1, \ldots, X \rightarrow A_k$ sont les seules DF de G avec X
    comme partie gauche (X est la clé de cette relation)
3. si aucune des relations de D ne contient une clé de R, créer une relation contenant les attributs qui forment une clé de R